


Agentic RAG: переход от RAG к ИИ-агентам

Новый уровень: Agentic RAG — RAG внутри ИИ-агента

Цель: превратить поисковую систему в активного участника диалога с целями и задачами




Чему посвящён модуль Agentic RAG

- Понять, что такое ИИ-агенты и чем они отличаются от обычных LLM-чатов
- Разобрать концепцию Agentic RAG на примере ресторана
- Научиться мыслить шагами и задачами агента, а не отдельными промптами

Agentic RAG

Архитектура извлечения и построения ответов, которая предполагает создание автономных агентных процессов



Напоминание: классический RAG

- Вход: вопрос пользователя
- Поиск релевантных фрагментов в базе (меню, документы и т.п.)
- Объединение контекста и вопроса → запрос к LLM
- Ответ на основе найденной информации
- Сильная сторона: доступ к актуальным данным и доменным знаниям
- Ограничение: один проход, без сложного поведения и диалога

Почему классического RAG уже недостаточно

- Пользователь ожидает диалог, а не один ответ
- Нужны уточняющие вопросы (аллергии, ограничения, предпочтения)
- Нужны разные ветки поведения: по теме меню / не по теме
- Нужен учёт контекста предыдущих сообщений (истории диалога)

Введение в ИИ-агентов

- ИИ-агент: система, которая воспринимает ситуацию, принимает решения и действует
- Работает в цикле: наблюдать → думать → действовать
- Использует инструменты (поиск, базы данных, RAG-цепочки) для достижения цели
- Отличается от «ответчика на промпт» тем, что живёт во взаимодействии с окружением

Агенты и окружение

- У агента всегда есть окружение: пользователь, данные, интерфейс
- Агент наблюдает за окружением (новые сообщения, состояние)
- Агент обновляет своё внутреннее состояние
- Агент воздействует на окружение: ответы, запросы к данным, новые вопросы

Агенты, цели и полезность

- У агента есть цель (например, помочь гостю выбрать подходящее блюдо)
- Агент оценивает свои действия относительно цели
- Важно не просто реагировать на текст, а приводить пользователя к результату

Агенты и действия

- Примеры действий агента: анализировать сообщение, делать поиск, задавать уточняющий вопрос, формировать ответ
- Агент комбинирует действия в последовательности
- Каждый шаг — маленькое решение: нужно ли сейчас привлекать RAG, или достаточно уточнить детали

ИИ-агент vs классический чат-бот

- Классический чат-бот: жёсткие правила «если $X \rightarrow$ то Y »
- Плохо переносит новые формулировки и комбинации вопросов
- ИИ-агент: основан на LLM, понимает естественный язык
- Принимает решения с учётом контекста и данных, гибко подстраивается

Связь ИИ-агентов и Agentic RAG

- RAG даёт агенту доступ к реальным данным (меню, документы)
- Агент даёт RAG контекст: цель, состояние диалога, момент запроса
- Agentic RAG = ИИ-агент, который использует RAG как один из инструментов

Сценарий ресторана: цифровой официант

- Окружение: гость ресторана и меню как база знаний
- Роль агента: вести диалог, понимать запросы, обращаться к меню по мере необходимости
- Ответы должны быть понятными и «человеческими»

Базовый RAG для меню ресторана

- Вопрос: «Какие блюда с креветками у вас есть?»
- Шаги базового RAG: вопрос → поиск по меню → генерация ответа
- Возвращается список блюд и краткие описания
- Это отправная точка перед переходом к Agentic RAG

Что добавляет «агентность» к RAG

Шаги до RAG-поиска: понять вопрос, проверить, относится ли он к меню, уточнить параметры

Шаги после RAG-поиска: выбрать релевантные результаты, оформить предложение, задать следующий вопрос

Агент может выполнять несколько RAG-запросов в рамках одного диалога

Агент как «оркестратор» действий

- Агент выбирает, когда использовать RAG, а когда нет
- Решает, нужен ли уточняющий вопрос или можно сразу отвечать
- Определяет момент завершения диалога
- RAG становится одним из инструментов агента, а не всем приложением

Многоходовой диалог с Agentic RAG

- Агент поддерживает контекст нескольких сообщений, запоминая предпочтения пользователя
- Каждый новый вопрос обрабатывается с учётом истории, а не в отрыве
- Это ключевое отличие от разового RAG-запроса

Плюсы и сложности Agentic RAG

- Плюсы: более естественный диалог, точный учёт целей пользователя, осмысленное использование данных
- Плюсы: гибкость в обработке неожиданных запросов
- Сложности: нужно проектировать поведение агента и его шаги
- Сложности: появляется управление состоянием диалога и ветвлениями сценариев

Как использовать этот модуль дальше

- Вы познакомились с базовой идеей ИИ-агентов и Agentic RAG
- Увидели, как RAG становится частью поведения агента
- Следующие шаги: состояние и память агента, практическая реализация цифрового официанта, тестирование
- Задача: научиться проектировать свои собственные агентные сценарии на базе RAG