

LLM


- Обзор LLM
- MoE-LLM
- Генерация ответов
- Промптинг
- Оптимизации инференса
- Transformers & Large Language Models

3 categories of Transformer-based models:

Encoder-decoder	Text to text	T5, mT5, ByT5
------------------------	--------------	---------------

3 категории моделей на базе Transformer:


- Encoder–decoder — «текст → текст» (T5, mT5, ByT5)



(Рисунок по мотивам «Attention Is All You Need», Vaswani и др., 2017)

3 categories of Transformer-based models:

Encoder-decoder	Text to text	T5, mT5, ByT5
Encoder-only	Projection of embedding for class prediction (e.g. sentiment extraction)	BERT, DistilBERT, RoBERTa




3 категории моделей на базе Transformer:

- Encoder-decoder — «текст → текст» (T5, mT5, ByT5)
- Encoder-only — проекция эмбединга для предсказания класса (напр., анализ тональности) — BERT, DistilBERT, RoBERTa

3 categories of Transformer-based models:

Encoder-decoder	Text to text	T5, mT5, ByT5
Encoder-only	Projection of embedding for class prediction (e.g. sentiment extraction)	BERT, DistilBERT, RoBERTa
Decoder-only	Text to text	GPT series



3 категории моделей на базе Transformer:

- Encoder–decoder — «текст → текст» (T5, mT5, ByT5)
- Encoder–only — проекция эмбединга для предсказания класса (напр., анализ тональности) — BERT, DistilBERT, RoBERTa
- Decoder–only — «текст → текст» — серия GPT




Терминология

LLM = Large Language Model (большая языковая модель)


«Языковая модель — это модель, назначающая вероятности последовательностям токенов».

- Размер модели: миллиарды параметров и выше
- Данные: сотни миллиардов токенов и больше
- Вычисления: много GPU

Decoder-only трансформер-модель





MoE = Mixture of Experts (смесь экспертов) -LLM




Идея: не все веса полезны в каждом прямом проходе.

Подмножество большой модели активируется под конкретный вход.







Эксперты E1 E2 ... En
G — маршрутизатор (gating)




Эксперты $E_1 \ E_2 \ \dots \ E_n$
 G — маршрутизатор (gating)
 $x \rightarrow \dots$ (выбраны топ- k экспертов)



Активируется лишь часть экспертов под конкретный токен/пример



MoE = Mixture of Experts



MoE = Mixture of Experts (смесь экспертов)


$E_1 \ E_2 \ \dots \ E_n$

G — роутер/маршрутизатор

$$\hat{y} = \sum_{i=1}^n G(x)_i E_i(x)$$

MoE = Mixture of Experts


Плотная (dense) MoE: выход — взвешенное среднее выходов всех экспертов.



Dense MoE. Output is weighted average of **all** expert outputs.

$$\hat{y} = \sum_{i=1}^n G(x)_i E_i(x)$$

MoE = Mixture of Experts



Sparse MoE. Output is weighted average of **selected** expert outputs.


$$\hat{y} = \sum_{i \in \mathcal{I}_k} G(x)_i E_i(x)$$

Via **top-k** selection


Разреженная (sparse) MoE: активируются только top-k экспертов.

См. «Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer», Shazeer и др., 2017.

МоЕ в трансформер-моделях



Nx





Nx

MoE в трансформер-моделях

Эксперты стоят на месте FFN: вместо одного MLP — набор MLP-экспертов.

Маршрутизация выполняется для каждого токена!

Routing done **for each token!**



Сложности обучения: «routing collapse»

Симптом: один и тот же эксперт выбирается слишком часто.

Решение: вспомогательное выравнивание нагрузки (aux loss).

auxiliary load-balancing loss штрафует дисбаланс: стимулирует, чтобы доля токенов и средние вероятности распределялись **равномернее** по экспертам.

Сложности обучения: «routing collapse»


Симптом: дисбаланс распределения токенов/вероятностей между экспертами. один и тот же эксперт выбирается слишком часто.

Мера: loss на баланс нагрузки = средняя доля токенов, направленных эксперту i , и средняя вероятность направления эксперту i .

$$\text{loss} = \alpha \cdot N \cdot \sum_{i=1}^N f_i \cdot P_i$$

f_i = fraction of tokens routed to expert i


P_i = average routing probability for expert i




LLM

The diagram shows a large, light blue rectangular block representing an LLM. Below the left side of this block is a smaller white rectangular box containing the text "[BOS]".

[BOS]







A


LLM


[BOS]


A





















1-я идея. Взять токен с наибольшей предсказанной вероятностью






1-я идея. Взять токен с наибольшей предсказанной вероятностью





Ограничения. Выход не оптимальный, неестественный и/или недостаточно разнообразный

2-я идея. Сохранить k наиболее вероятных путей






[BOS]

2-я идея. Сохранить k наиболее вероятных путей





2-я идея. Сохранить k наиболее вероятных путей







2-я идея. Сохранить k наиболее вероятных путей







2-я идея. Сохранить k наиболее вероятных путей






2-я идея. Сохранить k наиболее вероятных путей








2-я идея. Сохранить k наиболее вероятных путей




2-я идея. Сохранить k наиболее вероятных путей



Ends at [EOS]




2-я идея. Сохранить k наиболее вероятных путей




Ends at [EOS]

Limitations. Needs computations + lacks diversity/creativity


3-я идея. Выбрать следующий токен из распределения вероятностей:



$$\hat{w}_{t+1} \sim P(w_{t+1} | C)$$




Тор-к: Сэмплирование (случайный выбор) из k наиболее вероятных токенов




$k = 4$


$$P(w_{t+1} = w | C)$$



Тор-к: Сэмплирование (выборка) из k наиболее вероятных токенов




$k = 4$






Тор-р: Случайная выборка из наименьшего набора токенов, совокупная (накопленная) вероятность которых $\geq p$

$p = 90\%$






Как получить вероятности?



Проецирование векторного представления в пространство словаря.



Вычисление вероятностей




Вычисление вероятностей




$$P_{\text{adj}}(w_{t+1} = w_i | C) = \frac{\exp\left(\frac{x_i}{T}\right)}{\sum_{j=1}^n \exp\left(\frac{x_j}{T}\right)}$$

Small T



High T



Motivation. Generate output in a specific format

Input prompt

*Generate a description of my
33-year old teddy bear who
likes reading.*

Do this in JSON format.


Desired output (JSON)

```
{  
  "first_name": "teddy",  
  "last_name": "bear",  
  "age": 33,  
  "hobby": "reading"  
}
```


Idea. Only allow "valid" next tokens

[BOS]


Idea. Only allow "valid" next tokens




Idea. Only allow "valid" next tokens




Idea. Only allow "valid" next tokens




Idea. Only allow "valid" next tokens




Idea. Only allow "valid" next tokens




Idea. Only allow "valid" next tokens




Idea. Only allow "valid" next tokens




Idea. Only allow "valid" next tokens



Idea. Only allow "valid" next tokens



Промптинг: Как получить хороший ответ



Мой плюшевый мишка устал за день и ему нужна сказка на ночь.

● Контекст

Сгенерируй сказку на ночь, действие которой происходит в конкретном месте.

● Инструкции

Локация: страна плюшевых мишек

● Ввод

Сказка должна подходить уставшим плюшевым мишкам.

● Ограничения

Обучение с нулевой передачей (Zero-shot learning)

- Вопрос задается без примеров.
- Производительность сильно зависит от качества исходной модели.

Обучение с несколькими примерами (Few-shot learning)

- Промпт содержит примеры входных и выходных данных.
- Как правило, имеет более высокую производительность.

Показ примеров в промпте, как правило, лучше, но:

- Требует усилий.
- Увеличивает вычислительную сложность и стоимость.
- Увеличивает задержку (латентность).

Идея. Объяснение хода мыслей помогает улучшить производительность.

В: Сколько лет этому медведю?

О: Медведь родился в 2020 году. Следовательно, ему 4 года.


В: Сколько лет будет медведю в следующем году?

LLM **О:** В следующем году он будет на один год старше, чем его текущий возраст, который составляет 4 года. Следовательно, ему будет 5 лет.

Обсуждение:

- Интерпретируемость + объяснение
- Больше токенов: выше стоимость и задержка

Идея: Агрегирование путей рассуждения повышает точность.



Вычисления дороги, есть ли способ снизить сложность?
Категории. Много измерений для оптимизации.

Вычисления дороги, есть ли способ снизить сложность?
Категории. Много измерений для оптимизации.

«Точная» эффективность:

- Избегайте избыточности.
- Управление памятью.
- Переформулируйте математику.


Вычисления дороги, есть ли способ снизить сложность?
Категории. Много измерений для оптимизации.

«Точная» эффективность:


- Избегайте избыточности
- Управление памятью
- Переформулируйте математику

Аппроксимации:


- Архитектурные изменения
- Векторные представления (эмбединги)
- Предсказание токенов




Новый токен должен взаимодействовать со всеми предыдущими токенами.




Новый токен должен взаимодействовать со всеми предыдущими токенами.




Новый токен должен взаимодействовать со всеми предыдущими токенами.



Новый токен должен взаимодействовать со всеми предыдущими токенами.



Новый токен должен взаимодействовать со всеми предыдущими токенами.



Новый токен должен взаимодействовать со всеми предыдущими токенами.


$$\text{softmax} \left(\frac{Q \boxed{K^T}}{\sqrt{d_k}} \right) \boxed{V}$$

Новый токен должен взаимодействовать со всеми предыдущими токенами.

Идея. Хранить ключи и значения в кеше.



Новый токен должен взаимодействовать со всеми предыдущими токенами.

Идея. Хранить ключи и значения в кеше.




Новый токен должен взаимодействовать со всеми предыдущими токенами.

Идея. Хранить ключи и значения в кеше.




Новый токен должен взаимодействовать со всеми предыдущими токенами.

Идея. Хранить ключи и значения в кеше.




Новый токен должен взаимодействовать со всеми предыдущими токенами.

Идея. Хранить ключи и значения в кеше.




KV caching = Key-Value Caching




In vanilla MHA, Number of query heads = Number of key heads = Number of value heads = h

Idea. Share key/value attention heads within groups of queries




$$G = 1$$

Multi-**Q**uery **A**ttention
(MQA)




$$1 < G < h$$


Group-**Q**uery **A**ttention
(GQA)



$$G = h$$


Multi-**H**ead **A**ttention
(MHA)






Number of
query heads

$$= h$$



Number of
key heads

$$= G < h$$



Number of
value heads

$$= G < h$$