

Векторизация текстов

Классические подходы к обработке естественного языка

Что будет на уроке

Векторизация текстов

BoW (CountVectorizer)

TF-IDF

PMI

Эмбединги слов

Практика

Мешок слов BoW

Базовыми элементами текста являются слова

Используется информация только о наличии/отсутствии слова

Номер текста	вхождений слова «абрикос»	...	вхождений слова «ямал»
1	0	...	1
...	...	...	...
N	1	...	0

Мешок слов CountVectorizer

Слова могут встречаться много раз в тексте

Будем учитывать частоту встречания слова в тексте

Номер текста	вхождений слова «абрикос»	...	вхождений слова «ямал»
1	0	...	23
...	...	...	...
N	4	...	0

Мешок слов TF-IDF

Слова имеют разную значимость

Будем сглаживать веса слов

- Заменим в описании d счётчик слова на значение TF-IDF:

$$tfidf_{wd} = tf_{wd} \times \log \frac{|D|}{df_w}$$

- tf_{wd} — отношение числа вхождений слова w в d к общему числу слов в d
- df_w — число документов, содержащих w

Мешок слов TF-IDF

Признаки TF-IDF часто используются на практике и показывают хорошие результаты

Упускаем информацию о порядке слов в текстах

Важно при обработке устойчивых сочетаний слов (коллокации, словарные N-граммы)

Пример “глубокая нейронная сеть”

Выделяем коллокации

Обозначаем каждый из них отдельным токеном

Получаем для них матрицу (bow/tf-idf)

Pointwise Mutual Information (PMI)


Для оценки совместной встречаемости слов используют

- Один из вариантов оценки — PMI (*Pointwise Mutual Information*):

$$\text{PMI}(u, v) = \log \frac{N_{uv}}{N_u N_v}$$

- N_{uv} — число документов, содержащих оба слова u и v в окне заданного размера
- N_u — число документов, содержащих слово u

Эмбединги слов



Эмбединги слов

Семантическая близость слов

«Обычная» близость для слов

Например:

- компьютер
- ноутбук
- ПК
- лаптоп

Близость n -мерных векторов

$d(p, q)$, где p и q — векторы:

$$p = (p_1, p_2, \dots, p_n)$$

$$q = (q_1, q_2, \dots, q_n)$$

измеряется по-разному:


- Манхэттенское расстояние
- Евклидово расстояние
- Косинусное расстояние

Эмбединги слов



Эмбединги слов

- Пусть дана коллекция из m документов со словарём размера n
- Пусть $\mathbf{M} \in \mathbb{R}^{n \times m}$ — матрица «мешка слов»
- Применим SVD: $\mathbf{M} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$



Эмбединги слов

- В качестве векторных представлений слов можно взять строки матрицы $\mathbf{U}_k \sqrt{\Sigma_k}$

Абрикос
Апельсин
Арбуз
...
Черешня
Яблоко

$\mathbf{E} \in \mathbb{R}^{n \times k}$

$\mathbf{U}_k \in \mathbb{R}^{n \times k}$

$\sqrt{\Sigma_k} \in \mathbb{R}^{k \times k}$

Кстати:

для получения
векторов
раскладывая
можно не только
матрицу «мешка
слов»

Эмбединги слов

Что стало лучше:

- Векторы имеют фиксированную длину
- Они не взаимно ортогональны
- Семантическая близость как-то учитывается

Но:

- Добавление новых слов/документов потребует построение нового разложения
- Мы в явном виде должны работать с большой разреженной матрицей «мешка слов»
- Качество векторов можно улучшить